天津医科大学理论课教案首页

课程名称：Linux 系统概论　　**课程内容/章节：**高级 Linux 命令 / 第 8&9 章

教师姓名：伊现富　　**职称：**讲师　　**教学日期：**2019 年 5 月 28 日 13:30-15:10

授课对象：生物医学工程与技术学院 2017 级生信班（本）　　**听课人数：**28

授课方式：理论讲授　　**学时数：**2　　**教材版本：**Unix 入门经典，第 1 版

教学目的与要求（分掌握、熟悉、了解、自学四个层次）：

- 掌握常见的元字符，find 的使用，grep 的使用，sed 的使用，AWK 的使用。
- 熟悉正则表达式的构建，find 的常用测试，grep 的常用选项，sed 的工作原理，AWK 的工作原理和脚本结构。
- 了解 Linux 中的文本处理命令。
- 自学文本处理命令在生物信息学中的应用。

授课内容及学时分配：

- (5') 引言与导入：回顾 Linux 命令的基本格式以及常用的 Linux 命令，引申出授课内容。
- (20') 正则表达式和元字符：介绍正则表达式和元字符的概念，讲解元字符中的字符、字符集、量词和边界，举例说明正则表达式的构建。
- (20') find 和 grep：讲解 find 的常用测试并通过实例进行演示，讲解 grep 的常用选项并通过实例进行演示。
- (5') 文本处理命令：总结 Linux 中常用的文本处理命令。
- (40') sed 和 AWK：讲解 sed 的工作原理、定位规则和常用命令，通过实例演示 sed 的使用；讲解 AWK 的工作原理和脚本结构，通过实例演示 AWK 的使用。
- (5') 生物信息学中的应用：举例说明文本处理命令在生物信息学中的应用。
- (5') 总结与答疑：总结授课内容中的知识点与技能，解答学生疑问。

教学重点、难点及解决策略：

- 重点：元字符，find 的使用，grep 的使用。
- 难点：元字符，sed 的使用，AWK 的使用。
- 解决策略：通过实例讲解与操作演示帮助学生理解、记忆。

专业外语词汇或术语：

正则表达式（regular expression）　　字符集（character class）
元字符（metacharacter）　　模式空间（pattern space）

辅助教学情况：

- 多媒体：元字符，find 的测试，grep 的选项，sed 和 AWK 的工作原理。
- 板书：常见的元字符，正则表达式的构建与解析。
- 演示：find、grep、sed 和 AWK 的基本使用。

复习思考题：

- 列举五个常见的元字符并解释其含义。
- 根据要求编写正则表达式。
- 根据要求使用 find 查找文件。
- 根据要求使用 grep 查找字符串。
- 根据要求组合使用文本处理命令。
- 根据要求编写 sed 脚本编辑文件。
- 根据要求编写 AWK 脚本输出特定字段。
- 根据要求处理生物信息学文本数据。

参考资料：

- (美) Harley Hahn 著，张杰良 译。Unix & Linux 大学教程，清华大学出版社，2010。
- 鸟哥 著，王世江 改编。鸟哥的 Linux 私房菜——基础学习篇（第三版），人民邮电出版社，2010。
- (美) Ben Forta 著，杨涛 等译。正则表达式必知必会，人民邮电出版社，2007。
- 维基百科等网络资源。

主任签字：　　**年　月　日**　　**教务处制**

一、 引言与导入（5 分钟）

1. 回顾：Linux 命令的基本格式，常用的 Linux 命令
2. 介绍：正则表达式和元字符，find、grep、sed、AWK 等高级命令

二、 正则表达式和元字符（20 分钟）

1. 简介
   - 正则表达式：具有一定句法的集合或短语，包含元字符或普通字符，表示某类文本或字符串。
   - 元字符：代表一组字符或命令的字符，用最小的字符集表示多组文本。
   - 相关命令：less，more，grep，sed，AWK，vim，……
2. **【重点、难点】**元字符（结合实例讲解每一个元字符）
   - 字符：一般字符，`.`，`[]`，`[a-z]`，`[0-9]`，`[^]`，`\`
   - 字符集：`\d`，`\D`，`\s`，`\S`，`w`，`\W`
   - 量词：`?`，`*`，`+`，`{m}`，`{m,n}`
   - 边界：`^`，`$`
   - 其他：`()`，`|`

正则表达式	描　述	示　例
^	行起始标记	^tux 匹配以tux起始的行
$	行尾标记	tux$ 匹配以tux结尾的行
.	匹配任意一个字符	Hack.匹配Hackl和Hacki，但是不能匹配Hackl2和Hackil，它只能匹配单个字符
[]	匹配包含在[字符]之中的任意一个字符	coo[kl] 匹配cook或cool
[^]	匹配除[^字符]之外的任意一个字符	9[^01] 匹配92、93，但是不匹配91或90
[-]	匹配[]中指定范围内的任意一个字符	[1-5] 匹配从1～5的任意一个数字
?	匹配之前的项1次或0次	colou?r 匹配color或colour，但是不能匹配colouur
+	匹配之前的项1次或多次	Rollno-9+ 匹配Rollno-99、Rollno-9，但是不能匹配Rollno-
*	匹配之前的项0次或多次	co*l 匹配cl、col、coool等
()	创建一个用于匹配的子串	ma(tri)? 匹配max或maxtrix
{n}	匹配之前的项n次	[0-9]{3} 匹配任意一个三位数，[0-9]{3}可以扩展为[0-9][0-9][0-9]
{n,}	之前的项至少需要匹配n次	[0-9]{2,} 匹配任意一个两位或更多位的数字
{n,m}	指定之前的项所必需匹配的最小次数和最大次数	[0-9]{2,5} 匹配从两位数到五位数之间的任意一个数字
|	交替——匹配|两边的任意一项	Oct (1st | 2nd) 匹配Oct 1st或Oct 2nd
\	转义符可以将上面介绍的特殊字符进行转义	a\.b匹配a.b，但不能匹配ajb。通过在 . 之间加上前缀 \ ，从而忽略了 . 的特殊意义

3. 正则表达式

a. /^[A-Z]..$/ 查找文本中所有以大写字母开头、后跟两个任意字符，再跟一个换行符的行。查找结果是第 5 行的 Dan。

b. /^[A-Z][a-z]*3[0-5]/ 查找所有以大写字母开头、后跟零个或多个小写字母或空格，再跟数字 3 和一个 0~5 之间的数字的行。查找结果是第 2 行。

c. /[a-z]*\./ 查找包含跟在零个或多个小写字母后的句点的行。结果是第 1、2、7、8 行。

d. /^ *[A-Z][a-z][a-z]$/ 查找以零个或多个空格开头(注意：制表符不算空格)，后跟一个大写字母、两个小写字母和一个换行符的行。结果将是第 4 行的 Tom 和第 5 行的 Dan。

e. /^[A-Za-z]*[^,][A-Za-z]*$/ 查找以零个或多个大/小写字母开头，后跟一个非逗号的字符，再跟零个或多个大/小写字母和一个换行符的行。结果是第 5 行。

三、 grep 和 find（20 分钟）

1. 【重点】find（实例讲解、操作演示）

(1) 测试

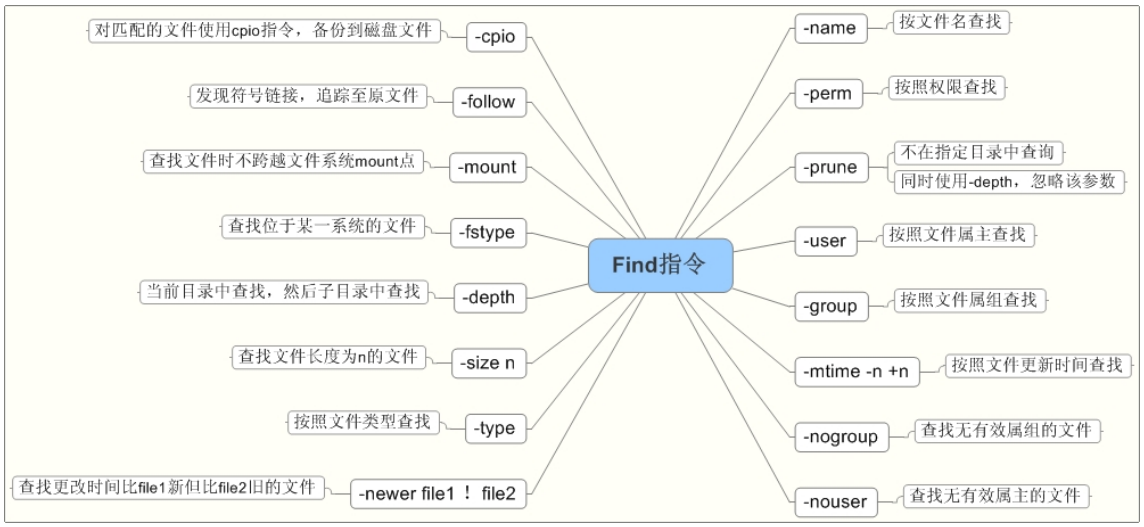

(2) 实例

- `find /etc -name passwd`
- `find /home -user USER`
- `find /home -size +2G -print`

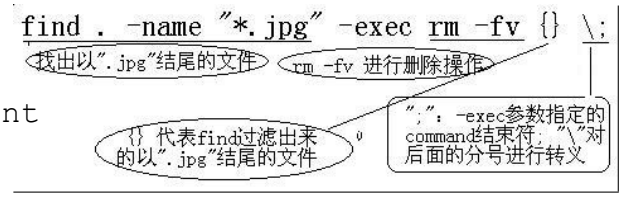

2. 【重点】grep（实例讲解、操作演示）

(1) 简介

定义 Globally search a Regular Expression and Print（全局正则表达式打印）

功能 在文件中搜索用户所指定的序列，然后将结果打印出来

用途 搜索文件或者在文件中进行查找

结构 `grep StringToSearchFor FileToSearch`

(2) 选项

(3) 实例

命令	显示
grep '[A-Z]' list	list 中包含一个大写字母的行
grep '[0-9]' data	data 中包含数字的行
grep '[A-Z]...[0-9]' list	list 中包含以大写字母开始、数字结尾的 5 个字符组合的行
grep '\.pic$' filelist	filelist 中以.pic 结尾的行

四、 文本处理命令（5 分钟）

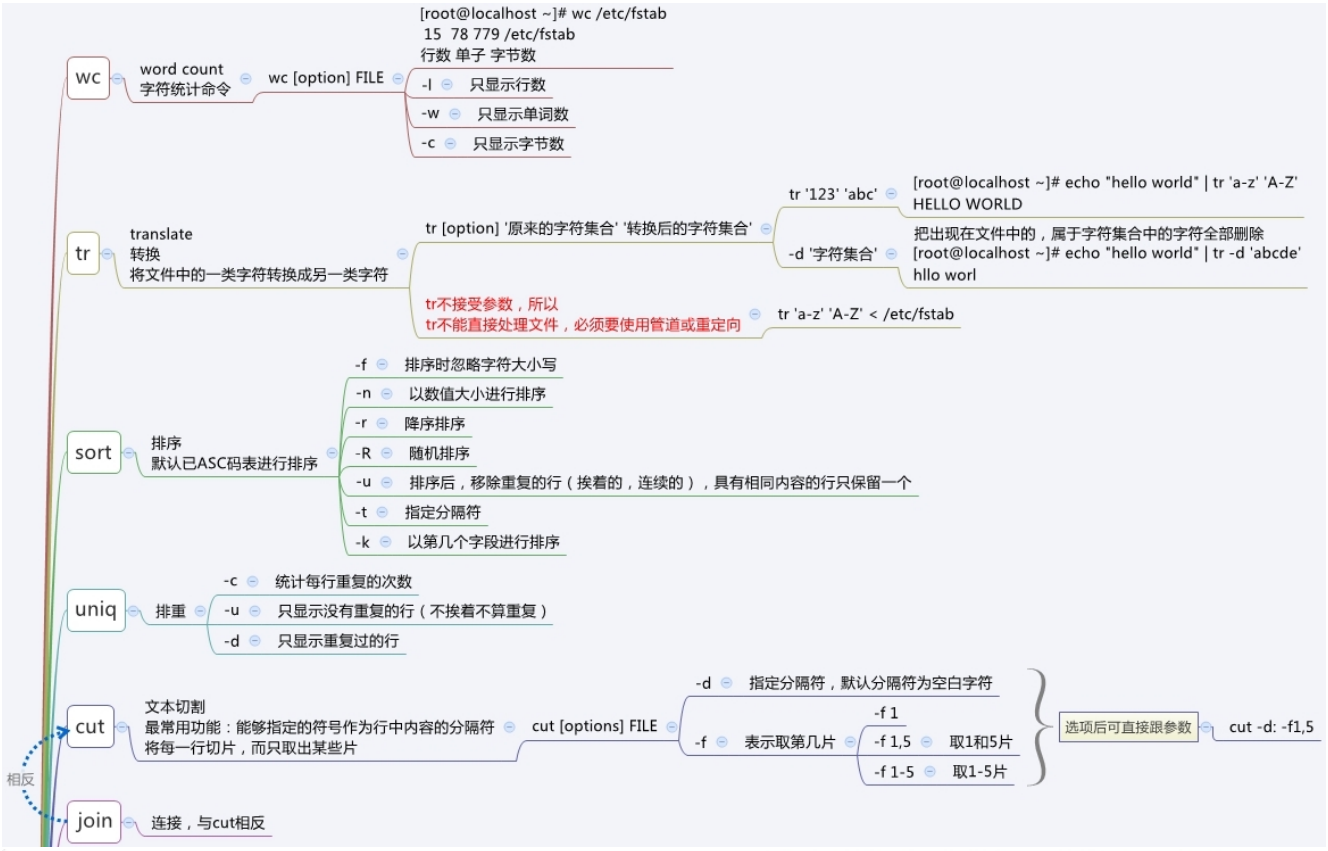

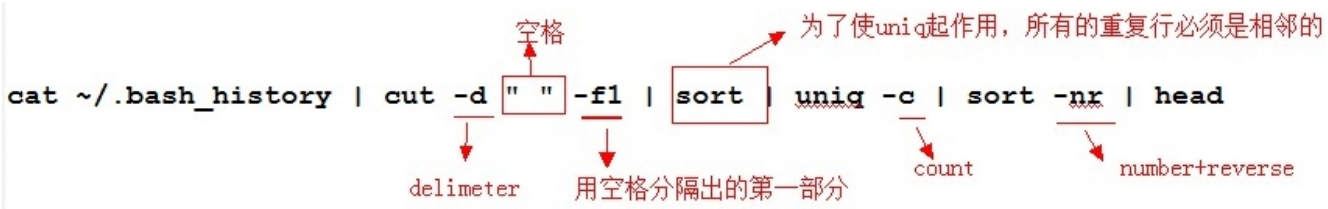

命令	说明	命令	说明
cat	组合文件	split	分割文件
tac	反转文本行的顺序	rev	反转字符串的顺序
head	从数据开头选择数据行	tail	从数据末尾选择数据行
less	显示文件	more	显示文件
colrm	删除数据列	cmp	比较任意两个文件
cut	抽取数据列/字段	paste	组合数据列
nl	创建行号	wc	统计行/单词/字符数量
fold	格式化行	fmt	格式化段落
sort	排序数据	uniq	查找重复行

命令	说明	命令	说明
join	合并两个文件中的有序数据	strings	在二进制文件中搜索字符串
tr	转换字符	tsort	由偏序创建全序
comm	比较有序文本文件	diff	比较无序文本文件
expand	将制表符转换成空格	unexpand	将空格转换成制表符
tee	管道分流	pr	按页/列格式化文本
grep	选取包含特定模式的行	look	查找以特定模式开头的行/单词
sed	非交互式文本编辑	awk	格式化输出
shuf	随机选取行/文件		

五、 sed 和 AWK（40 分钟）

1. 简介
   - sed：处理纯文本流的文本编辑器
   - AWK：一种输出格式化语言
   - 对象：已有文本（管道，命令，文本文件）
2. 【难点】sed（实例讲解、操作演示）
   (1) 工作原理
   (2) 定位
   (3) 命令

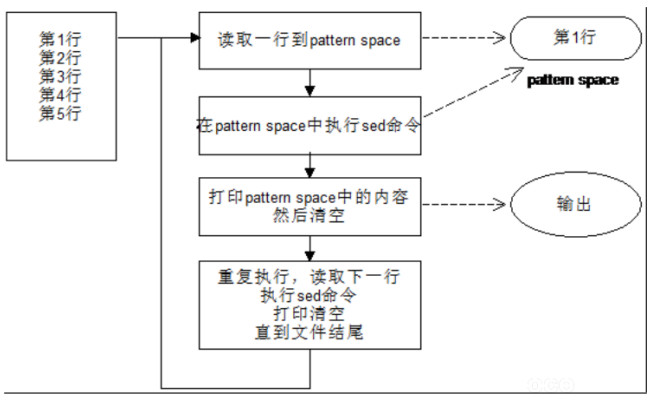

(4) 实例

- `sed -n '1,3!p' 123.txt`
- `sed -n -e '/the/p' -e '/the/=' 123.txt`
- `sed 's/this/that/g' 123.txt`
- `echo "hello" | sed 's/$/.txt/g'`
- `ls -l | sed -n '1,3p'`

命令	助记	说明
p	Print	打印匹配行
=	—	显示匹配行的行号
d	Delete	删除匹配行
a\	Append	在指定行后面追加文本
i\	Insert	在指定行后面插入文本
c\	Correct	用新文本替换指定行
s	Substitute	替换命令
l	List	显示指定行中的所有字符
r	Read	读取文件
w	Write	写入文件
n	Next	读取指定行的下一行
q	Quit	退出 sed

命令	说明
n	第 n 行
$	最后一行
m,n	从第 m 行到第 n 行
/pattern/	包含指定模式的行
/pattern/,n	从包含指定模式的行到第 n 行
n,/pattern/	从第 n 行到包含指定模式的行
/pattern1/,/pattern2/	从包含模式 1 的行到包含模式 2 的行
!	反向选择，不包含指定行，如*m,n!*

3. 【难点】AWK（实例讲解、操作演示）

(1) 工作原理

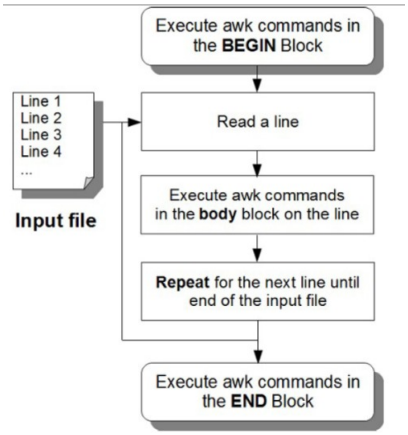

① 如果存在 **BEGIN**，**awk** 首先执行它指定的 **actions**

② **awk** 从输入中读取一行，称为一条输入记录

③ **awk** 将读入的记录分割成数个字段，并将第一个字段放入变量 **$1** 中，第二个放入变量 **$2** 中，以此类推；**$0** 表示整条记录；字段分隔符可以通过选项 **-F** 指定，否则使用缺省的分隔符。

④ 把当前输入记录依次与每一个 **awk_cmd** 中 **pattern** 比较：
如果相匹配，就执行对应的 **actions**；
如果不匹配，就跳过对应的 **actions**，直到完成所有的 **awk_cmd**

⑤ 当一条输入记录处理完毕后，**awk** 读取输入的下一行，重复上面的处理过程，直到所有输入全部处理完毕。

⑥ **awk** 处理完所有的输入后，若存在 **END**，执行相应的 **actions**

⑦ 如果输入是文件列表，**awk** 将按顺序处理列表中的每个文件。

(2) 脚本结构

```
1  awk
2
3    '
4    BEGIN {actions}
5
6      /pattern1/{actions}
7      ......
8      /patternN/{actions}
9
10   END {actions}
11   '
12
13 InputFile
```

有 10 个记录的文件，每个记录 4 个字段

(3) 常见变量

(4) 记录与字段

(5) 命令构成

- 编辑命令（一个、一组命令或一个命令文件）
  - 模式：只编辑与模式相匹配的记录行；没有提供模式时，匹配所有行
  - 命令：具体执行的编辑命令；没有指定命令时，打印整个记录行
- 要编辑的数据（数据或数据文件）

(6) 实例

- `awk '{print $0}' 123.txt`
- `ls -l | awk '{if($1 !~ /^d/) {print $0}}'`
- `awk '{printf("%03d %s\n",NR,$0)}' ori.txt > dst.txt`
- `awk 'BEGIN{FS=" ";OFS="\t"}{print $1,$2} ori.txt > dst.txt`

变量	描述
$n	当前记录的第n个字段，字段间由FS分隔。
$0	完整的输入记录。
ARGC	命令行参数的数目。
ARGIND	命令行中当前文件的位置(从0开始算)。
ARGV	包含命令行参数的数组。
CONVFMT	数字转换格式(默认值为%.6g)
ENVIRON	环境变量关联数组。
ERRNO	最后一个系统错误的描述。
FIELDWIDTHS	字段宽度列表(用空格键分隔)。
FILENAME	当前文件名。

FNR	同NR，但相对于当前文件。
FS	字段分隔符(默认是任何空格)。
IGNORECASE	如果为真，则进行忽略大小写的匹配。
NF	当前记录中的字段数。
NR	当前记录数。
OFMT	数字的输出格式(默认值是%.6g)。
OFS	输出字段分隔符(默认值是一个空格)。
ORS	输出记录分隔符(默认值是一个换行符)。
RLENGTH	由match函数所匹配的字符串的长度。
RS	记录分隔符(默认是一个换行符)。
RSTART	由match函数所匹配的字符串的第一个位置。
SUBSEP	数组下标分隔符(默认值是\034)。

六、 生物信息学中的应用（5 分钟）

1. 实例（对命令进行逐一解析）

- `grep '>' file.fasta | wc -l`
- `awk '/^>/{s=++d".fa"} {print > s}' multi.fa`
- `sed -n '1~4s/^@/>/p;2~4p' file.fq > file.fa`
- `cat file.txt | awk '$1=="1"' | awk '$3>=1000000' | awk '$3<=2000000'`
- `echo {A,C,T,G}{A,C,T,G}{A,C,T,G}`
- `grep -c $'\tgene\t' yourannots.gff3`
- `grep -v '^#' GFF3 | cut -s -f 3 | sort | uniq`
- `cut -f1,6 gene.bed | sort | uniq -c | sort -nr`
- `cat myfile.fq | awk '((NR-2)%4==0){read=$1;total++;count[read]++} END{for(read in count){if(!max||count[read]>max) {max=count[read];maxRead=read};if(count[read]==1){unique++}}; print total,unique,unique*100/total,maxRead,count[maxRead], count[maxRead]*100/total}'`

七、 总结与答疑（5 分钟）

1. 知识点
   - 元字符：字符，字符集，量词，边界
   - 正则表达式：构建，解析
   - find：常用测试，日常使用
   - grep：常用选项，日常使用
   - 文本处理命令：cut，wc，sort，uniq，…
   - sed：工作原理，定位方式，编辑命令
   - AWK：脚本结构，工作原理，常见变量，记录，字段
2. 技能
   - 解析并编写正则表达式
   - find 和 grep 的基本用法
   - 文本处理命令的日常应用
   - 使用 sed 和 AWK 处理文本
   - 正则表达式在 grep、sed 和 AWK 中的应用