天津医科大学实验课教案首页

课程名称：Linux 系统概论　　**实验名称：**实验 5 Linux 高级命令的操作

教师姓名：伊现富　　**职称：**讲师　　**教学日期：**2015 年 6 月 11 日 15:30-17:30

授课对象：生物医学工程学院 2013 级生信班（本）　　**实验人数：**28

实验类型（验证型、综合型、设计型、创新型）：验证型　　**实验分组：**一人一机

学时数：2　　**教材版本：**Linux 系统概论上机指南（自编教材）

实验目的与要求：

- 了解 datamash 的使用方法。
- 了解 Linux 命令在生物信息学文本处理中的应用。
- 掌握 find、grep、sed 和 AWK 的使用方法。

实验内容及学时分配：

- (10') 元字符和正则表达式：回顾元字符和正则表达式的基础知识。
- (10') 文本处理命令：通过实例回顾 find、grep、sed 和 AWK 的使用方法，总结常用的文本处理命令。
- (80') 实验操作：以 CentOS 发行版为例，练习 find、grep、sed 和 AWK 等高级命令的使用，掌握它们的基本语法。

主要仪器和实验材料：

- 主要仪器：一台安装有 CentOS 的计算机。

实验重点、难点及解决策略：

- 重点难点：正则表达式的构建，find、grep、sed 和 AWK 的基本语法。
- 解决策略：通过实例进行讲解，通过演示进行学习，通过练习熟练掌握。

思考题：

- 列举常见的元字符并解释其含义。
- 根据要求构建正则表达式。
- 使用 find、grep、sed 和 AWK 完成指定的任务。
- 根据要求组合使用文本处理命令。
- 根据要求使用 Linux 命令处理生物信息学文本数据。

参考资料：

- Linux 基础及应用习题解析与实验指导（第二版），谢蓉 编著。中国铁道出版社，2014。

一、 元字符和正则表达式（10分钟）

1. 简介

- 元字符：代表一组字符或命令的字符，用最小的字符集表示多组文本。
- 正则表达式：具有一定句法的集合或短语，包含元字符或普通字符，表示某类文本或字符串。
- 相关命令：less，more，grep，sed，AWK，vim，……

2. 元字符（结合实例与完整的正则表达式讲解每一个元字符）

- 字符：一般字符，`.`，`[]`，`[a-z]`，`[0-9]`，`[^]`，`\`
- 字符集：`\d`，`\D`，`\s`，`\S`，`w`，`\W`
- 量词：`?`，`*`，`+`，`{m}`，`{m,n}`
- 边界：`^`，`$`
- 其他：`()`，`|`

正则表达式	描　述	示　例
^	行起始标记	^tux 匹配以tux起始的行
$	行尾标记	tux$ 匹配以tux结尾的行
.	匹配任意一个字符	Hack.匹配Hackl和Hacki，但是不能匹配Hackl2和Hackil，它只能匹配单个字符
[]	匹配包含在[字符]之中的任意一个字符	coo[kl] 匹配cook或cool
[^]	匹配除[^字符]之外的任意一个字符	9[^01] 匹配92、93，但是不匹配91或90
[-]	匹配[]中指定范围内的任意一个字符	[1-5] 匹配从1～5的任意一个数字
?	匹配之前的项1次或0次	colou?r 匹配color或colour，但是不能匹配colouur
+	匹配之前的项1次或多次	Rollno-9+ 匹配Rollno-99、Rollno-9，但是不能匹配Rollno-
*	匹配之前的项0次或多次	co*l 匹配cl、col、coool等
()	创建一个用于匹配的子串	ma(tri)? 匹配max或maxtrix
{n}	匹配之前的项n次	[0-9]{3} 匹配任意一个三位数，[0-9]{3}可以扩展为[0-9][0-9][0-9]
{n,}	之前的项至少需要匹配n次	[0-9]{2,} 匹配任意一个两位或更多位的数字
{n,m}	指定之前的项所必需匹配的最小次数和最大次数	[0-9]{2,5} 匹配从两位数到五位数之间的任意一个数字
|	交替——匹配|两边的任意一项	Oct (1st | 2nd) 匹配Oct 1st或Oct 2nd
\	转义符可以将上面介绍的特殊字符进行转义	a\.b匹配a.b，但不能匹配ajb。通过在 . 之间加上前缀 \ ，从而忽略了 . 的特殊意义

3. 正则表达式

a. /^[A-Z]..$/ 查找文本中所有以大写字母开头、后跟两个任意字符，再跟一个换行符的行。查找结果是第5行的Dan。

b. /^[A-Z][a-z]*3[0-5]/ 查找所有以大写字母开头、后跟零个或多个小写字母或空格，再跟数字3和一个0~5之间的数字的行。查找结果是第2行。

c. /[a-z]*\./ 查找包含跟在零个或多个小写字母后的句点的行。结果是第1、2、7、8行。

d. /^ *[A-Z][a-z][a-z]$/ 查找以零个或多个空格开头(注意：制表符不算空格)，后跟一个大写字母、两个小写字母和一个换行符的行。结果将是第4行的Tom和第5行的Dan。

e. /^[A-Za-z]*[^,][A-Za-z]*$/ 查找以零个或多个大/小写字母开头，后跟一个非逗号的字符，再跟零个或多个大/小写字母和一个换行符的行。结果是第5行。

二、 文本处理命令（10 分钟）

1. find（通过实例讲解 find 的语法和使用）

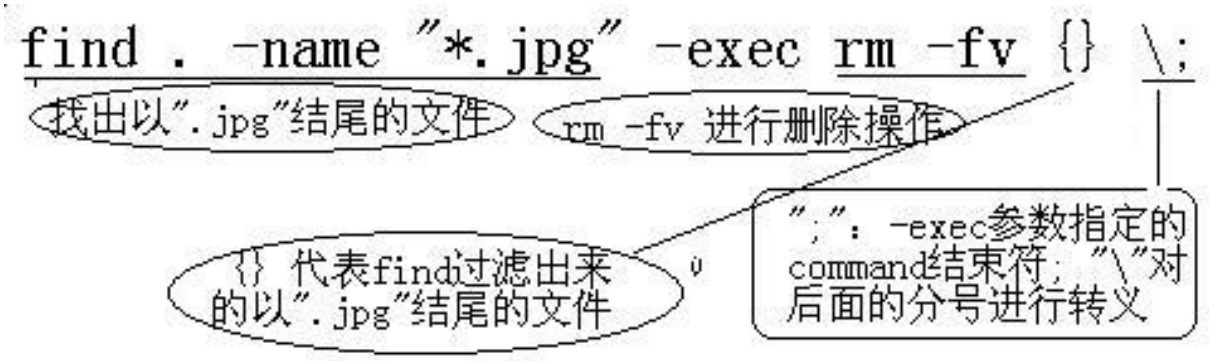

2. grep（通过实例讲解 grep 的语法和使用，注意正则表达式在其中的应用）

命令	显示
grep '[A-Z]' list	list 中包含一个大写字母的行
grep '[0-9]' data	data 中包含数字的行
grep '[A-Z]…[0-9]' list	list 中包含以大写字母开始、数字结尾的 5 个字符组合的行
grep '\.pic$' filelist	filelist 中以.pic 结尾的行

3. sed（通过实例讲解 sed 的语法和使用）

- `sed -n '1,3!p' 123.txt`
- `sed -n -e '/the/p' -e '/the/=' 123.txt`
- `sed 's/this/that/g' 123.txt`
- `echo "hello" | sed 's/$/.txt/g'`
- `ls -l | sed -n '1,3p'`

4. AWK（通过实例讲解 AWK 的语法和使用）

- `awk '{print $0}' 123.txt`
- `ls -l | awk '{if($1 !~ /^d/) {print $0}}'`
- `awk '{printf("%03d %s\n",NR,$0)}' ori.txt > dst.txt`
- `awk 'BEGIN{FS=" ";OFS="\t"}{print $1,$2} ori.txt > dst.txt`

5. 文本处理命令

(1) 常用文本处理命令

cut，sort，uniq，split，paste，join，comm，tr，……

(2) 使用实例

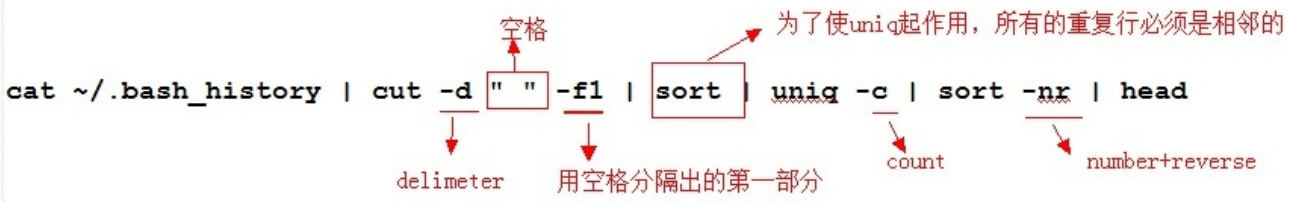

三、 实验操作（80分钟）

1. find 的使用
   (1) 根据文件名查找文件：-name，-iname
   (2) 限定搜索目录的深度：-maxdepth，-mindepth
   (3) 在找到的文件上执行命令（理解基本的语法，-exec vs. -ok）
   (4) 相反匹配：-not
   (5) 根据 inode 查找文件：-inum
   (6) 根据文件权限查找文件：-perm，-type
   (7) 查找空文件：-empty
   (8) 查找最大最小的文件（组合使用 find、sort 和 head）
   (9) 查找指定类型的文件：-type
   (10) 根据文件大小查找文件：-size，+，-
   (11) 根据时间戳查找文件：-mmin，-mtime，-amin，-atime，-cmin，-ctime
   (12) 基于文件比较进行查找：-newer，-anewer，-cnewer
2. grep 的使用（常用选项：-i，-v，-A，-B，-C，-c，-n，-w，-f）
3. sed 的使用（常用选项与命令：-e，-f；s，d）
4. AWK 的使用（基本语法结构，字段的含义）
5. datamash 的使用（学生课后自学，与 AWK、Perl、R 等进行比较）